

**LAPORAN STUDI KASUS**

**PENERAPAN ALGORITMA DBSCAN UNTUK DETEKSI**  
**ANOMALI**

**HARGA KOMODITAS PANGAN**



Disusun Oleh:  
**Rizky Pratama**  
NIM: F1E324021

Program Studi Informatika  
Fakultas Sains dan Teknologi  
Universitas Jambi

2026

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Harga pangan bergerak mengikuti pola yang tidak linear. Ada faktor musim, ada gejolak pasokan, ada kebijakan impor yang berubah tiba-tiba. Dalam kondisi seperti itu, pemantauan manual menjadi tidak efisien karena volume data yang dihasilkan sistem informasi pasar terus bertambah setiap harinya.

Deteksi anomali hadir untuk menjawab masalah tersebut. Bukan sekadar menemukan angka yang berbeda dari rata-rata, karena pendekatan statistik sederhana seperti batas dua standar deviasi terlalu kaku untuk data harga pangan yang secara alami memiliki variasi tinggi. Anomali dalam konteks ini bisa berupa lonjakan harga sesaat, penurunan mendadak di luar pola musiman, atau data terisolasi yang jauh dari kondisi pasar umum.

Di sinilah DBSCAN (Density-Based Spatial Clustering of Applications with Noise) relevan. Algoritma ini tidak memerlukan asumsi awal tentang jumlah cluster. Pengelompokan terbentuk secara organik berdasarkan kepadatan titik data, dan titik-titik yang berada di luar area padat secara otomatis ditandai sebagai noise. Noise inilah yang menjadi kandidat anomali.

Laporan ini mendokumentasikan penerapan DBSCAN pada dataset harga delapan komoditas pangan di Indonesia selama periode Juli 2016 sampai Januari 2026, mencakup 208.136 observasi setelah preprocessing, dengan tujuan mengidentifikasi pola harga yang menyimpang dari kondisi pasar normal secara sistematis.

### **1.2 Rumusan Masalah**

Berdasarkan latar belakang tersebut, laporan ini merumuskan tiga pertanyaan utama:

- a. Bagaimana algoritma DBSCAN dapat diterapkan untuk mendeteksi anomali harga komoditas pangan?
- b. Apa nilai parameter epsilon dan minPts yang optimal untuk dataset harga pangan yang digunakan?
- c. Bagaimana interpretasi anomali yang terdeteksi dalam konteks kejadian ekonomi aktual?

### **1.3 Tujuan**

Tujuan laporan ini adalah:

- a. Mengimplementasikan algoritma DBSCAN pada dataset harga delapan komoditas pangan.
- b. Menentukan parameter optimal (epsilon dan minPts) menggunakan metode k-distance graph.
- c. Mengidentifikasi dan menginterpretasikan titik anomali dalam konteks kondisi pasar yang relevan.

### **1.4 Manfaat**

Secara akademis, laporan ini menambah dokumentasi implementasi DBSCAN dalam domain ketahanan pangan. Secara praktis, pendekatan ini dapat menjadi referensi untuk membangun sistem pemantauan harga berbasis data yang lebih responsif terhadap gejolak pasar, tanpa bergantung pada pengamatan manual yang memerlukan banyak sumber daya.

## **BAB II**

### **LANDASAN TEORI**

#### **2.1 Clustering dalam Machine Learning**

Clustering adalah metode pembelajaran mesin tanpa pengawasan yang mengelompokkan data berdasarkan kemiripan internal, tanpa label yang ditentukan sebelumnya. Ada tiga pendekatan utama yang dikenal luas: berbasis partisi (seperti KMeans), berbasis hierarki (seperti agglomerative clustering), dan berbasis kepadatan (seperti DBSCAN).

KMeans bekerja dengan menghitung jarak setiap titik ke centroid cluster dan meminimalkan total jarak tersebut secara iteratif. Pendekatannya sederhana dan cepat, tapi ada dua batasan utama: jumlah cluster  $k$  harus ditentukan sebelum algoritma berjalan, dan cluster yang dihasilkan diasumsikan berbentuk bulat (spherical). Pada data harga pangan yang distribusinya tidak beraturan, dua asumsi itu sering tidak terpenuhi.

#### **2.2 DBSCAN**

DBSCAN dikembangkan oleh Ester et al. (1996) sebagai alternatif clustering untuk data dengan distribusi tidak seragam. Konsep dasarnya sederhana: titik yang berada di area padat dikelompokkan bersama, sedangkan titik yang terisolasi ditandai sebagai noise.

Algoritma ini tidak memerlukan input jumlah cluster. Cluster terbentuk secara organik berdasarkan kepadatan lokal, dan inilah yang membuatnya cocok untuk data dengan bentuk cluster yang tidak beraturan atau data yang secara alami mengandung outlier.

Proses DBSCAN berjalan sebagai berikut: untuk setiap titik yang belum dikunjungi, algoritma memeriksa apakah terdapat setidaknya  $\text{minPts}$  titik dalam radius  $\epsilon$ . Jika ada, titik itu menjadi core point dan cluster baru

dimulai. Titik-titik yang dapat dicapai dari core point secara density-reachable masuk ke cluster yang sama. Proses berlanjut sampai semua titik terklasifikasi.

### **2.3 Parameter DBSCAN**

Ada dua parameter yang menentukan perilaku DBSCAN: epsilon dan minPts.

Epsilon adalah radius yang mendefinisikan lingkungan di sekitar suatu titik. Semua titik yang berada dalam jarak epsilon dari titik referensi dianggap sebagai tetangganya. Nilai epsilon terlalu kecil akan menghasilkan terlalu banyak noise; nilai terlalu besar akan menggabungkan cluster yang seharusnya terpisah menjadi satu.

minPts adalah jumlah minimum titik yang harus ada dalam radius epsilon agar suatu titik diklasifikasikan sebagai core point. Nilai yang lazim digunakan adalah dua kali dimensi data, tapi perlu disesuaikan dengan kepadatan dan ukuran dataset.

Penentuan epsilon yang objektif dilakukan menggunakan k-distance graph: hitung jarak setiap titik ke tetangga ke-k terdekatnya, urutkan dari terkecil ke terbesar, lalu cari titik siku pada kurva. Nilai di titik siku itu menjadi epsilon yang direkomendasikan.

### **2.4 Jenis Titik dalam DBSCAN**

DBSCAN mengklasifikasikan setiap titik ke dalam salah satu dari tiga kategori:

Core point adalah titik yang memiliki setidaknya minPts tetangga dalam radius epsilon. Titik ini menjadi inti dari suatu cluster dan dapat memperluas cluster ke titik-titik di sekitarnya.

Border point adalah titik yang berada dalam radius epsilon dari sebuah core point, tapi tidak memiliki cukup tetangga untuk menjadi core point sendiri. Titik ini masuk ke cluster tapi tidak mendefinisikan batas cluster.

Noise point adalah titik yang tidak memenuhi kriteria core point maupun tidak terjangkau dari core point mana pun. Titik ini tidak masuk ke cluster mana pun dan menjadi kandidat anomali dalam analisis deteksi anomali.

Tabel 2.1 merangkum perbandingan karakteristik DBSCAN dengan KMeans:

| Karakteristik          | KMeans            | DBSCAN           |
|------------------------|-------------------|------------------|
| Input jumlah cluster   | Diperlukan (k)    | Tidak diperlukan |
| Bentuk cluster         | Spherical (bulat) | Arbitrer         |
| Deteksi outlier        | Tidak eksplisit   | Ya (noise point) |
| Sensitivitas parameter | k                 | epsilon, minPts  |

*Tabel 2.1. Perbandingan DBSCAN dan KMeans. Sumber: Adaptasi dari Schubert et al. (2017).*

## 2.5 Kelebihan dan Kekurangan DBSCAN

Kelebihan DBSCAN dibandingkan metode clustering berbasis partisi: tidak memerlukan input k, mampu mendeteksi cluster berbentuk arbitrer, dan secara eksplisit mengidentifikasi noise tanpa teknik tambahan.

Kekurangannya: sensitif terhadap pemilihan epsilon dan minPts, performa menurun pada data berdimensi tinggi karena curse of dimensionality, dan kurang efisien untuk dataset sangat besar jika tidak dikombinasikan dengan struktur indeks spasial seperti KD-tree.

## **BAB III**

### **METODOLOGI**

#### **3.1 Jenis Penelitian**

Penelitian ini bersifat deskriptif-eksploratif dengan pendekatan komputasional. Data harga pangan dianalisis menggunakan algoritma DBSCAN untuk mengidentifikasi pola anomali tanpa hipotesis awal tentang jumlah atau bentuk cluster yang diharapkan. Seluruh proses, mulai dari preprocessing hingga interpretasi hasil, didokumentasikan secara reproducible menggunakan Python 3.

#### **3.2 Dataset**

Dataset yang digunakan adalah data harga pangan dari WFP (World Food Programme) Food Prices Indonesia, mencakup delapan kelompok komoditas utama: beras (Rice), telur (Eggs), daging (Meat), gula (Sugar), minyak goreng (Oil), bawang putih (Garlic), bawang merah (Onions), dan cabai (Chili). Data mencakup periode Juli 2016 sampai Januari 2026 dengan total 208.136 observasi setelah preprocessing. Masing-masing observasi merepresentasikan satu pencatatan harga di pasar tertentu pada tanggal tertentu.

Komoditas asli berjumlah 27 varian kemudian dikelompokkan ke dalam 8 kelompok berdasarkan kemiripan jenis. Distribusi harga sangat bervariasi antar komoditas: beras dan gula relatif stabil, sementara Daging (Meat), bawang merah, dan cabai menunjukkan volatilitas tinggi.

Tabel 3.1 menampilkan statistik deskriptif dataset:

| <b>Komoditas</b> | <b>Min (Rp/kg)</b> | <b>Maks (Rp/kg)</b> | <b>Rata-rata</b> | <b>Std. Deviasi</b> |
|------------------|--------------------|---------------------|------------------|---------------------|
| Beras (Rice)     | 6.775              | 27.912              | 12.348           | 2.118               |
| Telur (Eggs)     | 1.631              | 80.000              | 26.836           | 4.929               |

|                       |        |         |        |        |
|-----------------------|--------|---------|--------|--------|
| Daging (Meat)         | 14.883 | 212.880 | 86.003 | 47.307 |
| Gula (Sugar)          | 9.829  | 45.000  | 15.446 | 2.020  |
| Minyak Goreng (Oil)   | 8.000  | 46.136  | 17.024 | 3.871  |
| Bawang Putih (Garlic) | 1.750  | 247.500 | 33.275 | 8.751  |
| Bawang Merah (Onions) | 11.364 | 100.476 | 36.840 | 10.309 |
| Cabai (Chili)         | 2.619  | 300.000 | 45.527 | 20.913 |

*Tabel 3.1. Statistik deskriptif dataset harga komoditas pangan 2016-2026. Sumber: WFP Food Prices Indonesia, diolah (2025).*

### 3.3 Preprocessing

Tahap preprocessing meliputi lima langkah. Pertama, penanganan missing values: baris dengan harga kosong atau tidak valid dihapus. Kedua, pengelompokan komoditas: 27 varian nama dikelompokkan ke dalam 8 kategori bersih. Ketiga, konversi tanggal ke nilai numerik ordinal. Keempat, normalisasi menggunakan StandardScaler (z-score) pada fitur date dan price. StandardScaler dipilih karena mempertahankan informasi outlier lebih baik dibandingkan MinMaxScaler yang menekan seluruh distribusi ke rentang [0, 1] dan membuat nilai ekstrem tampak lebih dekat ke data normal. Kelima, one-hot encoding pada delapan komoditas sehingga identitas komoditas ikut dipertimbangkan dalam perhitungan jarak.

Ruang fitur total yang digunakan adalah 10 dimensi: dua numerik (date\_scaled, price\_scaled) dan delapan biner komoditas. Dengan dimensionalitas 10, nilai minPts yang direkomendasikan adalah  $2 \times \text{dim} = 20$ .

Tabel 3.2 merangkum langkah preprocessing:

| Langkah             | Keterangan                         | Hasil                     |
|---------------------|------------------------------------|---------------------------|
| 1. Hapus missing    | Baris harga kosong/invalid dihapus | Data bersih 208.136 baris |
| 2. Grup komoditas   | 27 varian -> 8 kelompok bersih     | 8 commodity_clean         |
| 3. Konversi tanggal | Tanggal ke integer ordinal         | date_ordinal              |



|                     |                                   |                           |
|---------------------|-----------------------------------|---------------------------|
| 4. StandardScaler   | Z-score pada fitur date dan price | date_scaled, price_scaled |
| 5. One-hot encoding | 8 komoditas ke kolom biner (0/1)  | 8 fitur biner             |

*Tabel 3.2. Langkah preprocessing data harga pangan.*

### 3.4 Implementasi DBSCAN

Implementasi dilakukan menggunakan Python 3 dengan library scikit-learn. Dengan 10 dimensi fitur,  $\text{minPts} = 2 \times \text{dim} = 20$ . Nilai epsilon ditentukan melalui dua tahap.

Tahap pertama adalah k-distance graph. Jarak setiap titik ke tetangga ke-20 terdekatnya ( $k = \text{minPts}$ ) dihitung pada sampel acak 20.000 titik, lalu diurutkan. Titik siku terdeteksi di epsilon  $\sim 0,44$  menggunakan algoritma Kneedle. Namun nilai ini menghasilkan hanya 23 noise point (0,01%) karena dataset sangat padat. Titik siku digunakan sebagai batas atas pencarian, bukan nilai final langsung.

Tahap kedua adalah uji sensitivitas. Epsilon diuji pada tujuh nilai dalam rentang  $[0,10; 0,44]$  dengan minPts tetap 20. Silhouette Score dihitung tanpa noise point menggunakan subsampel 10.000 titik. Epsilon = 0,18 dipilih karena merupakan nilai pertama yang mencapai Silhouette Score tertinggi (0,51) sekaligus mempertahankan 276 noise point (0,13%) — lebih banyak dari nilai epsilon yang lebih besar — sehingga lebih informatif untuk analisis anomali.

Kode implementasi inti:

```

from sklearn.cluster import DBSCAN
from sklearn.neighbors import NearestNeighbors
import numpy as np

# X: array (208136, 10) -- StandardScaler + one-hot

# Tahap 1: k-distance graph (k = minPts = 20)
nn = NearestNeighbors(n_neighbors=20, n_jobs=-1).fit(X)
dists, _ = nn.kneighbors(X)
kdist = np.sort(dists[:, -1])

# Tahap 2: DBSCAN parameter final

```

```
db = DBSCAN(eps=0.18, min_samples=20, n_jobs=-1).fit(X)
labels = db.labels_ # -1 = noise
n_noise = np.sum(labels == -1) # = 276
```

### 3.5 Evaluasi

Evaluasi dilakukan menggunakan dua pendekatan. Pertama, Silhouette Score dihitung hanya pada titik yang masuk ke dalam cluster (label != -1) menggunakan subsampel 10.000 titik untuk efisiensi komputasi. Noise point dikecualikan karena tidak memiliki keanggotaan cluster yang valid. Kedua, analisis kontekstual dengan mencocokkan noise point terhadap kejadian ekonomi yang tercatat selama periode penelitian.

## BAB IV

### HASIL DAN PEMBAHASAN

#### 4.1 Eksplorasi Data

Dataset mencakup 208.136 observasi harga dari delapan komoditas pangan selama periode Juli 2016 hingga Januari 2026. Beras menunjukkan distribusi paling stabil dengan rata-rata Rp 12.348 per kilogram dan standar deviasi Rp 2.118. Gula pasir juga relatif stabil di Rp 15.446 per kilogram.


Komoditas bervolatilitas tinggi adalah cabai dan Daging (Meat). Harga cabai memiliki rentang Rp 2.619 hingga Rp 300.000 per kilogram dengan beberapa pencatatan ekstrem pada awal 2024. Daging sapi berkisar antara Rp 14.883 hingga Rp 212.880 per kilogram dengan peningkatan signifikan sejak 2022. Minyak goreng mengalami lonjakan tajam pada pertengahan 2022 akibat kebijakan larangan ekspor CPO, naik dari kisaran Rp 14.000 ke Rp 46.136 per kilogram sebelum turun pasca-intervensi.

Setelah StandardScaler, fitur `price_scaled` memiliki rentang -1,07 hingga +7,61, menunjukkan asimetri kuat di ekor kanan yang mengindikasikan adanya harga-harga ekstrem sebagai kandidat kuat anomali.


## 4.2 Penentuan Parameter Optimal

K-distance graph untuk  $k = 20$  dihitung pada sampel acak 20.000 titik. Kurva 20-distance menunjukkan kenaikan konsisten dengan infleksi yang terdeteksi di sekitar  $\epsilon = 0,44$ . Namun epsilon ini menghasilkan hanya 23 noise point (0,01%) karena data sangat padat. Titik siku digunakan sebagai batas atas pencarian, bukan nilai final.

Uji sensitivitas pada tujuh nilai epsilon menunjukkan Silhouette Score maksimum pertama pada  $\epsilon = 0,18$  (skor 0,51), nilai yang sama dengan epsilon 0,22 hingga 0,30 namun dengan noise point lebih banyak sehingga lebih informatif. Epsilon = 0,18 dipilih karena mencapai nilai Silhouette maksimum pertama sekaligus mempertahankan 276 noise point (0,13%) untuk analisis anomali yang informatif.



*Gambar 4.1. Grafik k-distance ( $k=20$ , sampel 20.000 titik). Titik siku di  $\epsilon \sim 0,44$  digunakan sebagai batas atas pencarian.*



Gambar 4.2. Kurva uji sensitivitas epsilon: Silhouette Score (biru, kiri) dan persentase noise (oranye, kanan). Epsilon = 0,18 terpilih.

Tabel 4.1 merangkum hasil uji sensitivitas parameter:

| Epsilon | minPts | Jumlah Cluster | Noise Point   | Silhouette Score |
|---------|--------|----------------|---------------|------------------|
| 0,10    | 20     | 30             | 1.492 (0,72%) | 0,44             |
| 0,14    | 20     | 22             | 658 (0,32%)   | 0,44             |
| 0,18    | 20     | 19             | 276 (0,13%)   | 0,51 *           |
| 0,22    | 20     | 20             | 147 (0,07%)   | 0,51             |
| 0,26    | 20     | 19             | 101 (0,05%)   | 0,51             |
| 0,30    | 20     | 19             | 58 (0,03%)    | 0,51             |
| 0,44    | 20     | 18             | 23 (0,01%)    | 0,43             |

Tabel 4.1. Hasil uji sensitivitas parameter DBSCAN. \* = parameter terpilih.

### 4.3 Hasil Clustering DBSCAN

Dengan parameter epsilon = 0,18 dan minPts = 20, DBSCAN menghasilkan 19 cluster dan 276 noise point dari total 208.136 observasi (0,13%). Silhouette Score yang diperoleh adalah 0,51 (dihitung tanpa noise point, subsampel 10.000 titik).


Delapan cluster terbesar masing-masing didominasi oleh satu komoditas, mencerminkan bahwa pola temporal harga setiap komoditas membentuk kelompok

tersendiri dalam ruang fitur 10 dimensi. Cluster 0 (beras, 28.355 titik), Cluster 1 (telur, 16.053), Cluster 2 (Daging/Meat, 15.852), Cluster 3 (gula, 21.614), Cluster 4 (minyak goreng, 21.607), Cluster 5 (bawang putih, 15.938), Cluster 6 (bawang merah, 15.668), dan Cluster 7 (Daging/Meat, 20.043) merepresentasikan pola harga normal sepanjang periode. Sebelas cluster lebih kecil (cluster 8–18, total 52.730 titik, 25,3%) menangkap variasi harga pada periode-periode tertentu, termasuk cluster 18 (35.646 titik) yang mencerminkan pola harga cabai pada rentang waktu tertentu.

Tabel 4.2 menampilkan ringkasan hasil clustering:

| Cluster   | Jumlah Titik | Persen | Komoditas Dominan | Karakteristik                      |
|-----------|--------------|--------|-------------------|------------------------------------|
| 0         | 28.355       | 13,6%  | Beras             | Pola harga stabil 2016-2026        |
| 1         | 16.053       | 7,7%   | Telur             | Fluktuasi moderat                  |
| 2         | 15.852       | 7,6%   | Daging (Meat)     | Tren meningkat gradual             |
| 3         | 21.614       | 10,4%  | Gula              | Pola harga stabil                  |
| 4         | 21.607       | 10,4%  | Minyak goreng     | Termasuk periode krisis 2022       |
| 5         | 15.938       | 7,7%   | Bawang putih      | Volatilitas musiman                |
| 6         | 15.668       | 7,5%   | Bawang merah      | Volatilitas musiman                |
| 7         | 20.043       | 9,6%   | Daging sapi       | Harga tinggi, tren naik pasca-2021 |
| 8-18      | 52.730       | 25,3%  | Campuran          | Pola harga khusus                  |
| Noise(-1) | 276          | 0,13%  | Daging & Cabai    | Anomali: harga terisolasi          |

Tabel 4.2. Ringkasan hasil clustering DBSCAN ( $\epsilon=0,18$ ,  $\minPts=20$ ).



*Gambar 4.3. Scatter plot hasil DBSCAN (date\_scaled vs price\_scaled). Tanda silang merah = noise point (anomali).*

#### 4.4 Analisis Anomali (Noise Point)

Dari 276 noise point, distribusi per komoditas didominasi oleh daging (Meat, 113 titik, 41%) dan cabai (Chili, 110 titik, 40%), disusul bawang merah (18), telur (16), bawang putih (7), gula (7), dan minyak goreng (5). Konsentrasi anomali pada daging dan cabai konsisten dengan volatilitas tinggi kedua komoditas.

Secara temporal, anomali terbanyak terjadi pada Maret 2017 (37 titik dalam satu bulan), Juli 2022 (13 titik), dan Januari 2024 (9 titik). Maret 2017 bertepatan dengan lonjakan harga cabai ekstrem akibat gagal panen. Juli 2022 bertepatan dengan dampak La Nina pada hortikultura sekaligus efek kebijakan CPO. Januari 2024 mencatat harga cabai mencapai Rp 300.000 per kilogram.

Periode COVID-19 (2020-2021) menunjukkan peningkatan anomali: 51 titik pada 2020 dan 25 titik pada 2021, mencerminkan gangguan rantai pasok dan disparitas harga antar wilayah akibat pembatasan distribusi.


Contoh konkret: pada 15 Januari 2024, harga cabai di beberapa pasar mencapai Rp 300.000 per kilogram, lebih dari tujuh kali rata-rata cluster normal. DBSCAN menandainya noise karena tidak ada cukup titik data lain yang cukup

dekat dalam ruang 10 dimensi. Sebaliknya, data minyak goreng pada krisis 2022 tetap masuk cluster karena lonjakan terjadi masif dan serentak, membentuk densitas lokal yang cukup untuk dikenali sebagai cluster tersendiri.

Tabel 4.3 merangkum distribusi noise point per komoditas:

| Komoditas             | Jumlah Anomali | Persentase | Harga Anomali Tertinggi      |
|-----------------------|----------------|------------|------------------------------|
| Daging (Meat)         | 113            | 41%        | Rp 212.879/kg (Agustus 2022) |
| Cabai (Chili)         | 110            | 40%        | Rp 300.000/kg (Januari 2024) |
| Bawang Merah (Onions) | 18             | 7%         | Rp 100.476/kg                |
| Telur (Eggs)          | 16             | 6%         | Rp 80.000/kg                 |
| Bawang Putih (Garlic) | 7              | 3%         | Rp 247.500/kg                |
| Gula (Sugar)          | 7              | 3%         | Rp 45.000/kg                 |
| Minyak Goreng (Oil)   | 5              | 2%         | Rp 46.136/kg                 |

Tabel 4.3. Distribusi noise point (anomali) per komoditas.



Gambar 4.4. Distribusi temporal noise point per bulan (2016-2026). Puncak utama: Maret 2017, Juli 2022, Januari 2024.

### 4.5 Perbandingan dengan KMeans

KMeans dengan  $k = 8$  (sesuai jumlah komoditas) diuji sebagai pembanding. KMeans tidak mengidentifikasi noise secara eksplisit karena setiap titik dipaksa

masuk ke cluster terdekat. Akibatnya, 276 titik yang DBSCAN tandai sebagai anomali tersebar di berbagai cluster tanpa bisa dibedakan dari data normal.

Untuk menggunakan KMeans sebagai detektor anomali, diperlukan langkah tambahan: menghitung jarak setiap titik ke centroid clusternya dan menetapkan ambang batas skor anomali secara terpisah. DBSCAN menghasilkan label anomali secara inheren dalam satu proses, menjadikannya pendekatan yang lebih tepat untuk pemantauan harga pangan berbasis data.

## **BAB V**

### **KESIMPULAN**

#### **5.1 Kesimpulan**

DBSCAN dengan parameter  $\epsilon = 0,18$  dan  $\text{minPts} = 20$  berhasil mendeteksi 276 titik anomali (0,13% dari 208.136 observasi) pada data harga komoditas pangan periode Juli 2016 sampai Januari 2026. 19 cluster terbentuk dengan Silhouette Score 0,51.

Anomali yang terdeteksi konsisten dengan kejadian ekonomi yang tercatat: lonjakan cabai ekstrem Maret 2017, krisis pasokan minyak goreng dan dampak La Nina Juli 2022, serta lonjakan harga cabai hingga Rp 300.000/kg pada Januari 2024. Ini mengonfirmasi bahwa label noise yang dihasilkan DBSCAN memiliki makna kontekstual, bukan sekadar artefak algoritma.

Parameter  $\epsilon = 0,18$  dipilih melalui kombinasi k-distance graph (batas atas) dan uji sensitivitas tujuh nilai, menghasilkan Silhouette Score 0,51. Pendekatan dua tahap ini terbukti lebih objektif daripada penetapan epsilon secara coba-coba.

#### **5.2 Saran**



Ada tiga hal yang dapat dikembangkan dari penelitian ini:

- a. Tambahkan fitur eksternal seperti data curah hujan, volume pasokan pasar, atau indeks harga komoditas global untuk memperkaya representasi data dan meningkatkan akurasi deteksi anomali.
- b. Bandingkan hasil DBSCAN dengan HDBSCAN atau OPTICS untuk melihat stabilitas deteksi anomali pada variasi parameter yang lebih lebar dan dataset yang lebih heterogen.
- c. Integrasikan pendekatan ini ke dalam sistem pemantauan harga pangan real-time, sehingga deteksi anomali berjalan otomatis setiap kali data baru masuk, bukan hanya secara batch.

## DAFTAR PUSTAKA

- Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96), 226-231.
- Kriegel, H. P., Kroger, P., Sander, J., & Zimek, A. (2011). Density-based clustering. Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 1(3), 231-240.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Schubert, E., Sander, J., Ester, M., Kriegel, H. P., & Xu, X. (2017). DBSCAN revisited, revisited: Why and how you should (still) use DBSCAN. ACM Transactions on Database Systems, 42(3), 1-21.
- Tan, P. N., Steinbach, M., Karpatne, A., & Kumar, V. (2019). Introduction to Data Mining (2nd ed.). Pearson.
- Kementerian Perdagangan Republik Indonesia. (2023). Laporan Perkembangan Harga dan Ketersediaan Bahan Pokok 2022-2023. Kemendag RI.